

0 课程安排及相关知识

- 推导SVM待优化的**基本形式** (☆)
 - 向量基本知识: 向量内积、内积几何意义, 向量范数计算方法等。
- 推导SVM待优化的**进阶形式** (☆☆☆☆)
 - 高数基本知识: 函数求导, 矩阵乘法。
 - **拉格朗日乘数法和KKT条件**: 基本原理, 表现形式, 求解方法。
 - **梯度知识**: 什么是梯度, 梯度方向是什么方向?
- 使用**SMO算法**进行求解 (☆☆☆☆)
- 深度学习版本的SVM (☆☆☆)
 - 机器学习知识: 损失函数, 分类任务、回归任务, 神经网络知识。
- SVM的程序调用 (☆☆☆)
 - <https://scikit-learn.org/stable/modules/generated/sklearn.svm.SVC.html>
 - 参数讲解, 其他应用中的相关知识。

基本原理


拓展知识

di yi zhang jie

第	一	章	节
---	---	---	---

推导SVM待优化的基本形式

(☆☆)





一组**线性可分**的数据，考虑一个问题，如右图展示的几条直线，都是能够将数据进行正确二分类的，问：哪个划分是最好的？

直觉告诉我：**黑色的是最好的。**

理由：黑色的看起来“容错性、健壮性”最好。在机器学习中也称“泛化性”更好。


分割平面距离边界向量越远越好



分割平面对应的几何间隔越大越好

N维空间的超平面

其中 w, x, b 均为N维列向量。



$$w^T x + b = 0$$

绿色虚线: $w^T x + b = \pm k$

分类时: $w^T x + b \geq k$, 归为+1类,
 $w^T x + b \leq -k$, 归为-1类。

实际中: 由于对超平面的权重系数做等规模放缩不影响超平面的性质。因此


$$W^T x + b = \pm k \Rightarrow w^T x + b = \pm 1$$

找一组超平面的 w, b 使得两组绿色虚线间隔最大。

间隔的计算

- 2维距离: $ax + by + c = 0$, $d = \frac{|c_1 - c_2|}{\sqrt{a^2 + b^2}}$

- 平行线（面）之间的距离(n维): $w^T x + b = \pm 1$, $d = \frac{2}{\sqrt{w^T w}}$


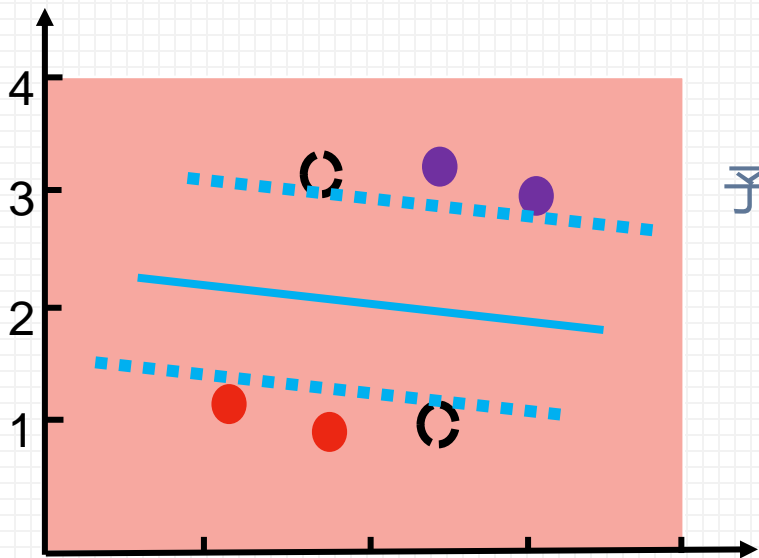


找一组超平面的 w b 使得两组绿色虚线间隔最大。

$$\max \frac{2}{\sqrt{w^T w}} \rightarrow \max \frac{2}{w^T w} \rightarrow \min \frac{1}{2} w^T w$$

SVM基本形式I, n 个样本 (x_i, y_i) , $x_i \in R^N, y_i \in \{+1, -1\}$:

$$\min \frac{1}{2} w^T w, \text{ s.t. } y_i (w^T x_i + b) \geq 1$$



也许一味地坚持硬性条件: $y_i(w^T x_i + b) \geq 1$, 并不是最好的, 也许给予模型一点点宽容, 反而能带来模型的泛化能力的提高。所以约束条变为:

$$y_i(w^T x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0$$

但是, ξ_i 整体又不能太大。体现为:

$$\min \frac{1}{2} w^T w + C \sum_i \xi_i$$

C 成为惩罚系数, 平衡模型的 “软硬程度”。

SVM基本形式2, n 个样本 (x_i, y_i) , $x_i \in R^N, y_i \in \{+1, -1\}$:

$$\begin{aligned} \min & \frac{1}{2} w^T w + C \sum_i \xi_i \\ \text{s.t.} & y_i(w^T x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0 \end{aligned}$$

di er zhang jie

第	二	章	节
---	---	---	---

推导SVM待优化的进阶形式

(☆ ☆ ☆ ☆)

硬间隔SVM目标: $\min \frac{1}{2} w^T w, \text{ s.t. } y_i (w^T x_i + b) \geq 1$

构造拉格朗日函数:

$$L(w, b, \alpha) = \frac{1}{2} w^T w + \sum_i \alpha_i [1 - y_i (w^T x_i + b)] \text{ s.t. } \alpha_i \geq 0$$

$$\because \max_{\alpha} L(w, b, \alpha) = \frac{1}{2} w^T w$$

$$\therefore \min_{w, b} \frac{1}{2} w^T w = \min_{w, b} \max_{\alpha} L(w, b, \alpha)$$

$$\mathbf{**对偶: \min_{w, b} \max_{\alpha} L(w, b, \alpha) = \max_{\alpha} \min_{w, b} L(w, b, \alpha)**}$$



我们不加证明的指出上式在SVM问题中是成立的, 并且相应的解满足KKT条件。

[1] 李航. 统计学习方法[M]. 清华大学出版社, 2012. 附录C。

[2] <https://zhuanlan.zhihu.com/p/219284970>

目标函数:

$$\max_{\alpha} \min_{w, b} L(w, b, \alpha), \quad s.t. \quad \alpha_i \geq 0$$

$$L(w, b, \alpha) = \frac{1}{2} w^T w + \sum_i \alpha_i [1 - y_i (w^T x_i + b)]$$

先求 L 关于 w, b 的极小值:

$$\frac{\partial L}{\partial w} = 0 \Rightarrow w - \sum_i \alpha_i y_i x_i = 0 \Rightarrow \mathbf{w} = \sum_i \alpha_i y_i \mathbf{x}_i$$

$$\frac{\partial L}{\partial b} = 0 \Rightarrow - \sum_i \alpha_i y_i = 0 \Rightarrow \sum_i \alpha_i y_i = 0$$

将 L 拆开, 并将相关结果带入:

$$L(w, b, \alpha) = \frac{1}{2} w^T w + \sum_i \alpha_i - \sum_i \alpha_i y_i w^T x_i - b \sum_i \alpha_i y_i$$

$$L(w, b, \alpha) = \frac{1}{2}w^T w + \sum_i \alpha_i - \sum_i \alpha_i y_i w^T x_i - b \sum_i \alpha_i y_i$$

$$= \frac{1}{2}w^T w + \sum_i \alpha_i - \sum_i \alpha_i y_i w^T x_i - 0$$

$$= \frac{1}{2}(\sum_i \alpha_i y_i x_i)^T (\sum_i \alpha_i y_i x_i) + \sum_i \alpha_i - \sum_i \alpha_i y_i (\sum_i \alpha_i y_i x_i)^T x_i$$

$$= \frac{1}{2}(\sum_i \alpha_i y_i x_i)^T (\sum_j \alpha_j y_j x_j) + \sum_i \alpha_i - \sum_i \alpha_i y_i (\sum_j \alpha_j y_j x_j)^T x_i$$

为防止混淆, 将w写为 $\sum_j \alpha_j y_j x_j$

$$= \frac{1}{2} \sum_i \sum_j \alpha_i \alpha_j y_i y_j (x_i^T x_j) + \sum_i \alpha_i - \sum_i \sum_j \alpha_i \alpha_j y_i y_j (x_i^T x_j)$$

$$= \sum_i \alpha_i - \frac{1}{2} \sum_i \sum_j \alpha_i \alpha_j y_i y_j (x_i^T x_j), \text{ s.t. } \alpha_i \geq 0, \sum_i \alpha_i y_i = 0$$

$$w = \sum_i \alpha_i y_i x_i$$

$$\sum_i \alpha_i y_i = 0$$

SVM进阶形式 1, n个样本 (x_i, y_i) , $x_i \in R^N, y_i \in \{+1, -1\}$:

$$\max \sum_i \alpha_i - \frac{1}{2} \sum_i \sum_j \alpha_i \alpha_j y_i y_j (x_i^T x_j)$$

$$\text{s.t. } \alpha_i \geq 0, \sum_i \alpha_i y_i = 0$$

软间隔SVM目标: $\min \frac{1}{2} w^T w + C \sum_i \xi_i, \quad s.t. \quad y_i (w^T x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0$

构造拉格朗日函数:

$$L(w, b, \alpha, \mu, \xi) = \frac{1}{2} w^T w + C \sum_i \xi_i + \sum_i \alpha_i [1 - \xi_i - y_i (w^T x_i + b)] + \sum_i \mu_i (-\xi_i)$$

$$s.t. \quad \alpha_i \geq 0, \quad \mu_i \geq 0, \quad \xi_i \geq 0$$

$$\because \max_{\alpha, \mu} L(w, b, \alpha, \mu, \xi) = \frac{1}{2} w^T w + C \sum_i \xi_i$$

$$\because \min_{w, b, \xi} \frac{1}{2} w^T w + C \sum_i \xi_i = \min_{w, b, \xi} \max_{\alpha, \mu} L(w, b, \alpha, \mu, \xi)$$

$$**\text{对偶: } \min_{w, b, \xi} \max_{\alpha, \mu} L(w, b, \alpha, \mu, \xi) = \max_{\alpha, \mu} \min_{w, b, \xi} L(w, b, \alpha, \mu, \xi)**$$



我们不加证明的指出上式在SVM问题中是成立的, 并且相应的解满足KKT条件。

目标函数:

$$\max_{\alpha, \mu} \min_{w, b, \xi} L(w, b, \alpha, \mu, \xi), \quad s.t. \quad \alpha_i \geq 0, \quad \mu_i \geq 0, \quad \xi_i \geq 0$$

$$L(w, b, \alpha, \mu, \xi) = \frac{1}{2} w^T w + C \sum_i \xi_i + \sum_i \alpha_i [1 - \xi_i - y_i (w^T x_i + b)] + \sum_i \mu_i (-\xi_i)$$

先求 L 关于 w, b, ξ 的极小值:

$$\frac{\partial L}{\partial w} = 0 \Rightarrow w - \sum_i \alpha_i y_i x_i = 0 \Rightarrow \mathbf{w} = \sum_i \alpha_i y_i x_i$$

$$\frac{\partial L}{\partial b} = 0 \Rightarrow - \sum_i \alpha_i y_i = 0 \Rightarrow \sum_i \alpha_i y_i = 0$$

$$\frac{\partial L}{\partial \xi_i} = 0 \Rightarrow C - \alpha_i - \mu_i = 0$$

将 L 拆开，并将相关结果带入：

$$L(w, b, \alpha) = \frac{1}{2} w^T w + C \sum_i \xi_i + \sum_i \alpha_i [1 - \xi_i - y_i (w^T x_i + b)] + \sum_i \mu_i (-\xi_i) \quad \rightarrow \sum_i (C - \alpha_i - \mu_i) \xi_i = 0$$

$$= \frac{1}{2} w^T w + \boxed{C \sum_i \xi_i} + \sum_i \alpha_i \boxed{-\sum_i \alpha_i \xi_i} - \sum_i \alpha_i y_i w^T x_i - b \sum_i \alpha_i y_i \boxed{-\sum_i \mu_i \xi_i}$$

$$= \frac{1}{2} (\sum_i \alpha_i y_i x_i)^T (\sum_i \alpha_i y_i x_i) + \sum_i \alpha_i - \sum_i \alpha_i y_i (\sum_i \alpha_i y_i x_i)^T x_i$$

$$= \frac{1}{2} (\sum_i \alpha_i y_i x_i)^T (\sum_j \alpha_j y_j x_j) + \sum_i \alpha_i - \sum_i \alpha_i y_i (\sum_j \alpha_j y_j x_j)^T x_i \quad \left. \vphantom{\sum_j} \right\} \text{为防止混淆，将} w \text{写为} \sum_j \alpha_j y_j x_j$$

$$= \frac{1}{2} \sum_i \sum_j \alpha_i \alpha_j y_i y_j (x_i^T x_j) + \sum_i \alpha_i - \sum_i \sum_j \alpha_i \alpha_j y_i y_j (x_i^T x_j)$$

....., s.t. $\alpha_i \geq 0, \sum_i \alpha_i y_i = 0$

$$= \sum_i \alpha_i - \frac{1}{2} \sum_i \sum_j \alpha_i \alpha_j y_i y_j (x_i^T x_j), \quad \boxed{\text{s.t. } \alpha_i \geq 0, \mu_i \geq 0, \xi_i \geq 0, \sum_i \alpha_i y_i = 0, C - \alpha_i - \mu_i = 0}$$

SVM进阶形式 2, n 个样本 (x_i, y_i) , $x_i \in R^N, y_i \in \{+1, -1\}$:


$$\max \sum_i \alpha_i - \frac{1}{2} \sum_i \sum_j \alpha_i \alpha_j y_i y_j (x_i^T x_j)$$

$$\text{s.t. } \alpha_i \geq 0, \mu_i \geq 0, \xi_i \geq 0, C - \alpha_i - \mu_i = 0, \sum_i \alpha_i y_i = 0$$




$$\text{s.t. } C \geq \alpha_i \geq 0, \mu_i \geq 0, \xi_i \geq 0, \sum_i \alpha_i y_i = 0$$

第 2.5 章 节

非线性可分与核技巧



在 2 维平面，红色点坐标 (a,b) 在半径为 1 的圆内部，紫色坐标在圆外部，不是线性可分的。



可以构造 z 纬度: $z = ab$, 得到升纬后的新坐标 (a, b, ab) 。如图
所示, 可以使用 $z = 1$ 平面进行线性划分。

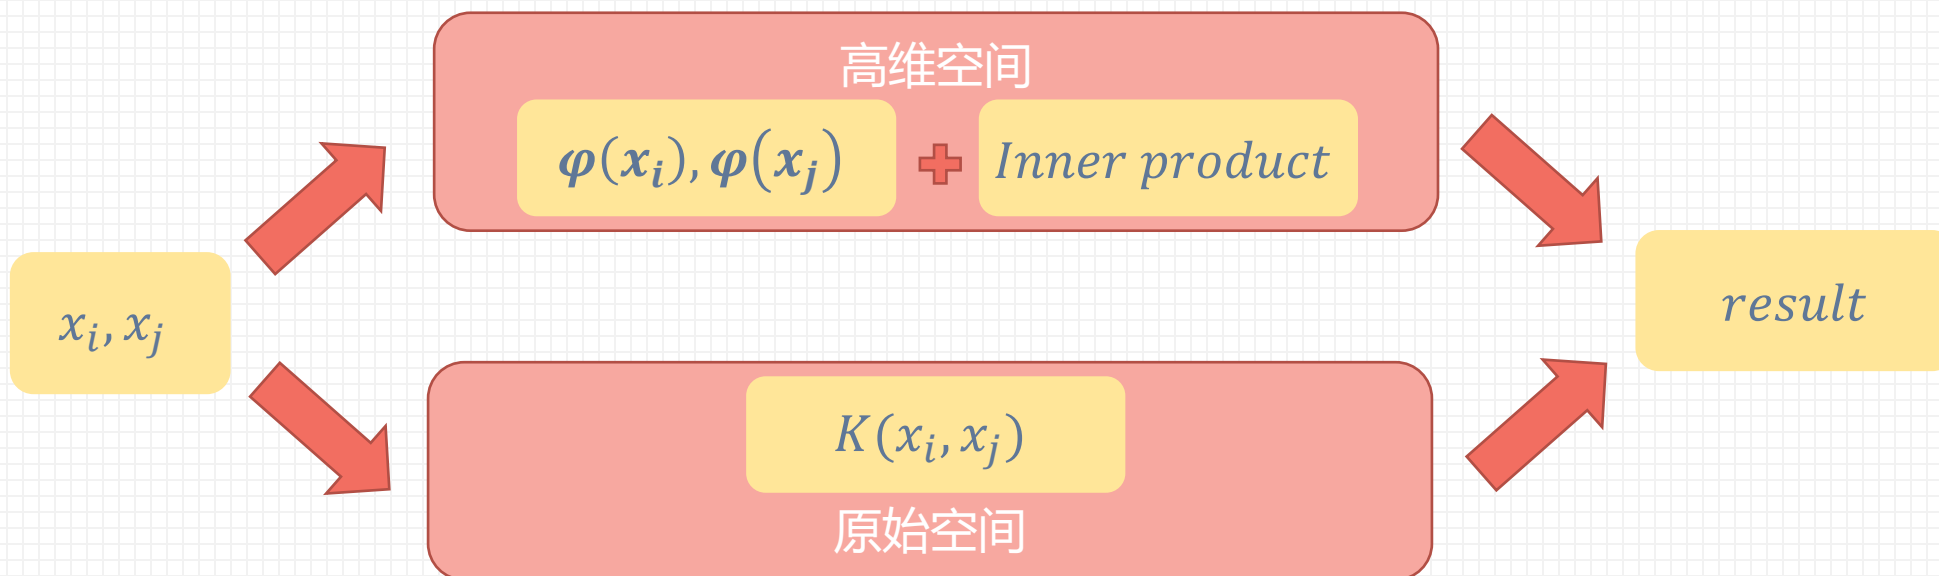
因此, 对于线性不可分的情况, 我们可以先对样本 x 升纬度, 然后进行
后续推导。记升维后的样本为 $\tilde{x} = \varphi(x)$ 。

$$\max \sum_i \alpha_i - \frac{1}{2} \sum_i \sum_j \alpha_i \alpha_j y_i y_j (x_i^T x_j)$$

$$\max \sum_i \alpha_i - \frac{1}{2} \sum_i \sum_j \alpha_i \alpha_j y_i y_j \tilde{x}_i^T \tilde{x}_j$$

1. 使用 $\varphi(\cdot)$ 对变量升维 $\Rightarrow \tilde{x}_i = \varphi(x_i)$
2. 计算升维后的 $\varphi(x_i)$ 与 $\varphi(x_j)$ 的内积

有没有一种可能，我们可以直接通过一个 $K(x_i, x_j)$ 直接得到 x_i, x_j 升维后的内积呢？



$$\begin{aligned}
 x &= \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \\
 \phi(x) &= \begin{bmatrix} x_1^2 \\ \sqrt{2}x_1x_2 \\ x_2^2 \end{bmatrix} \\
 K(x, z) &= \phi(x) \cdot \phi(z) = \begin{bmatrix} x_1^2 \\ \sqrt{2}x_1x_2 \\ x_2^2 \end{bmatrix} \cdot \begin{bmatrix} z_1^2 \\ \sqrt{2}z_1z_2 \\ z_2^2 \end{bmatrix} \\
 &= x_1^2z_1^2 + 2x_1x_2z_1z_2 + x_2^2z_2^2 \\
 &= (x_1z_1 + x_2z_2)^2 = \left(\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} \cdot \begin{bmatrix} z_1 \\ z_2 \end{bmatrix} \right)^2 \\
 &= (x \cdot z)^2
 \end{aligned}$$

$$\begin{aligned}
 K(x, z) &= (x \cdot z)^2 \\
 &= (x_1z_1 + x_2z_2 + \dots + x_kz_k)^2 \\
 &= \underline{x_1^2z_1^2} + \underline{x_2^2z_2^2} + \dots + \underline{x_k^2z_k^2} \\
 &\quad + 2\underline{x_1x_2z_1z_2} + 2\underline{x_1x_3z_1z_3} + \dots \\
 &\quad + 2\underline{x_2x_3z_2z_3} + 2\underline{x_2x_4z_2z_4} + \dots \\
 &= \phi(x) \cdot \phi(z)
 \end{aligned}$$

$$x = \begin{bmatrix} x_1 \\ \vdots \\ x_k \end{bmatrix} \quad z = \begin{bmatrix} z_1 \\ \vdots \\ z_k \end{bmatrix}$$

$$\phi(x) = \begin{bmatrix} x_1^2 \\ \vdots \\ x_k^2 \\ \sqrt{2}x_1x_2 \\ \sqrt{2}x_1x_3 \\ \vdots \\ \sqrt{2}x_2x_3 \\ \vdots \end{bmatrix}$$

Radial Basis Function Kernel

$$x = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \end{bmatrix} \quad z = \begin{bmatrix} z_1 \\ z_2 \\ \vdots \end{bmatrix}$$

$$K(x, z) = \exp\left(-\frac{1}{2}\|x - z\|_2^2\right) = \phi(x) \cdot \phi(z)?$$

$\phi(*)$ has inf dim!!!

$$\begin{aligned}
 &= \exp\left(-\frac{1}{2}\|x\|_2^2 - \frac{1}{2}\|z\|_2^2 + x \cdot z\right) \\
 &= \exp\left(-\frac{1}{2}\|x\|_2^2\right) \exp\left(-\frac{1}{2}\|z\|_2^2\right) \exp(x \cdot z) = C_x C_z \exp(x \cdot z)
 \end{aligned}$$

$$= C_x C_z \sum_{i=0}^{\infty} \frac{(x \cdot z)^i}{i!} = C_x C_z + C_x C_z (x \cdot z) + C_x C_z \frac{1}{2} (x \cdot z)^2 \dots$$

$$\begin{aligned}
 &[C_x] \cdot [C_z] \quad \begin{bmatrix} C_x x_1 \\ C_x x_2 \\ \vdots \end{bmatrix} \cdot \begin{bmatrix} C_z z_1 \\ C_z z_2 \\ \vdots \end{bmatrix} \quad \frac{1}{\sqrt{2}} \begin{bmatrix} C_x x_1^2 \\ \vdots \\ \sqrt{2} C_x x_1 x_2 \\ \vdots \end{bmatrix} \cdot \frac{1}{\sqrt{2}} \begin{bmatrix} C_z z_1^2 \\ \vdots \\ \sqrt{2} C_z z_1 z_2 \\ \vdots \end{bmatrix}
 \end{aligned}$$

$$\begin{aligned}
 &[C_x, C_x x_1, C_x x_2, \dots, C_x x_1^2, \dots, \sqrt{2} C_x x_1 x_2, \dots, C_x x_1^{99}, \dots] \\
 &[C_z, C_z z_1, C_z z_2, \dots, C_z z_1^2, \dots, \sqrt{2} C_z z_1 z_2, \dots, C_z z_1^{99}, \dots]
 \end{aligned}$$

李宏毅老师官网主页, B站也有人搬运。
包括线性代数, 机器学习, 深度学习等。



$$\max \sum_i \alpha_i - \frac{1}{2} \sum_i \sum_j \alpha_i \alpha_j y_i y_j (x_i^T x_j) \quad \xrightarrow{\text{升维}} \quad \max \sum_i \alpha_i - \frac{1}{2} \sum_i \sum_j \alpha_i \alpha_j y_i y_j (\varphi(x_i)^T \varphi(x_j))$$

核技巧

SVM进阶形式 3, n 个样本 (x_i, y_i) , $x_i \in R^N, y_i \in \{+1, -1\}$:

$$\begin{aligned} \max \sum_i \alpha_i - \frac{1}{2} \sum_i \sum_j \alpha_i \alpha_j y_i y_j K(x_i, x_j) \\ \text{s.t. } C \geq \alpha_i \geq 0, \quad \mu_i \geq 0, \quad \xi_i \geq 0, \quad \sum_i \alpha_i y_i = 0 \end{aligned}$$

到此，我们学习了SVM的基本形式，该模型属于凸优化问题，可以使用凸优化包对上述问题进行求解。下面我们将学习针对SVM的更加高效的优化方法：SMO(Sequential minimal optimization).

di	san	zhang	jie
第	三	章	节

使用SMO算法进行求解

(☆☆☆☆)

$$\max \sum_i \alpha_i - \frac{1}{2} \sum_i \sum_j \alpha_i \alpha_j y_i y_j K(x_i, x_j)$$

$$\text{s.t. } C \geq \alpha_i \geq 0, \mu_i \geq 0, \xi_i \geq 0, \sum_i \alpha_i y_i = 0$$

SMO算法的思想：同时调整 n 个变量太复杂，可以固定一些变量，调整少量的变量，反正能改善模型性能就好。每次调整少的变量，简单还快。



我们每次调整1个变量，固定 $n-1$ 个变量。

不行，因为 $\sum_i \alpha_i y_i = 0$ ，确定其余 $n-1$ 个，那么最后1个变量也就固定了。



那就每次调整2个，固定 $n-2$ 个吧。

鼠鼠你啊，真滴是太棒辣！



$$\text{不妨设 } \alpha_1 y_1 + \alpha_2 y_2 = D, \quad \alpha_1 = \frac{(D - \alpha_2 y_2)}{y_1} = y_1(D - \alpha_2 y_2), \quad \alpha_i \in [0, C].$$

$$\begin{aligned}
& \max \sum_i \alpha_i - \frac{1}{2} \sum_i \sum_j \alpha_i \alpha_j y_i y_j K(x_i, x_j) \\
& \text{s.t. } C \geq \alpha_i \geq 0, \mu_i \geq 0, \xi_i \geq 0, \sum_i \alpha_i y_i = 0
\end{aligned}
\quad \xrightarrow{\text{忽略条件}} \quad \min \frac{1}{2} \sum_i \sum_j \alpha_i \alpha_j y_i y_j k_{ij} - \sum_i \alpha_i$$

$$\begin{aligned}
& \min \frac{1}{2} \sum_i \sum_j \alpha_i \alpha_j y_i y_j k_{ij} - \sum_i \alpha_i \\
& = \frac{1}{2} \sum_i \sum_j \alpha_i \alpha_j y_i y_j k_{ij} - (\alpha_1 + \alpha_2) - \sum_{i=3} \alpha_i \\
& = \frac{1}{2} (\sum_{i=1}^2 \sum_j \alpha_i \alpha_j y_i y_j k_{ij} + \sum_{i=3} \sum_j \alpha_i \alpha_j y_i y_j k_{ij}) - (\alpha_1 + \alpha_2) - \sum_{i=3} \alpha_i \\
& = \frac{1}{2} [\sum_{i=1}^2 (\sum_{j=1}^2 \alpha_i \alpha_j y_i y_j k_{ij} + \sum_{j=3} \alpha_i \alpha_j y_i y_j k_{ij}) + \sum_{i=3} \sum_j \alpha_i \alpha_j y_i y_j k_{ij}] - (\alpha_1 + \alpha_2) - \sum_{i=3} \alpha_i \\
& = \frac{1}{2} [\sum_{i=1}^2 (\sum_{j=1}^2 \alpha_i \alpha_j y_i y_j k_{ij} + \sum_{j=3} \alpha_i \alpha_j y_i y_j k_{ij}) + \sum_{i=3} (\sum_{j=1}^2 \alpha_i \alpha_j y_i y_j k_{ij} + \sum_{j=3} \alpha_i \alpha_j y_i y_j k_{ij})] - (\alpha_1 + \alpha_2) - \sum_{i=3} \alpha_i \\
& = \frac{1}{2} k_{11} \alpha_1^2 + \frac{1}{2} k_{22} \alpha_2^2 + \alpha_1 \alpha_2 y_1 y_2 k_{12} + \sum_{i=1}^2 \sum_{j=3} \alpha_i \alpha_j y_i y_j k_{ij} - (\alpha_1 + \alpha_2) + \frac{1}{2} \sum_{i=3} \sum_{j=3} \alpha_i \alpha_j y_i y_j k_{ij} - \sum_{i=3} \alpha_i
\end{aligned}$$

$$= \frac{1}{2} k_{11} \alpha_1^2 + \frac{1}{2} k_{22} \alpha_2^2 + \alpha_1 \alpha_2 y_1 y_2 k_{12} + \alpha_1 y_1 \sum_{j=3} \alpha_j y_j k_{1j} + \alpha_2 y_2 \sum_{j=3} \alpha_j y_j k_{2j} - (\alpha_1 + \alpha_2)$$

$$\min \frac{1}{2}k_{11}\alpha_1^2 + \frac{1}{2}k_{22}\alpha_2^2 + \alpha_1\alpha_2y_1y_2k_{12} + \alpha_1y_1 \sum_{j=3} \alpha_j y_j k_{1j} + \alpha_2y_2 \sum_{j=3} \alpha_j y_j k_{2j} - (\alpha_1 + \alpha_2)$$

记: $v_i = \sum_{j=3} \alpha_j y_j k_{ij}$, 又前边推得 $w = \sum_j \alpha_j y_j x_j$, 所以

$$f(x_i) = w^T x_i + b = \left(\sum_j \alpha_j y_j x_j \right)^T x_i + b = \sum_j \alpha_j y_j x_j^T x_i + b = \sum_j \alpha_j y_j k_{ij} + b$$



$$\begin{aligned} v_i &= f(x_i) - \sum_{j=1}^2 \alpha_j y_j k_{ij} - b \\ \alpha_1 &= y_1(D - \alpha_2 y_2) \end{aligned}$$

$$\begin{aligned} \min \quad & \frac{1}{2}k_{11}(y_1(D - \alpha_2 y_2))^2 + \frac{1}{2}k_{22}\alpha_2^2 + y_1(D - \alpha_2 y_2)\alpha_2 y_1 y_2 k_{12} + y_1(D - \alpha_2 y_2)y_1 v_1 + \alpha_2 y_2 v_2 - (y_1(D - \alpha_2 y_2) + \alpha_2) \\ & \frac{1}{2}k_{11}(D - \alpha_2 y_2)^2 + \frac{1}{2}k_{22}\alpha_2^2 + (D - \alpha_2 y_2)\alpha_2 y_2 k_{12} + (D - \alpha_2 y_2)v_1 + \alpha_2 y_2 v_2 - y_1(D - \alpha_2 y_2) - \alpha_2 \end{aligned}$$

$$\Leftrightarrow \frac{\partial obj}{\partial \alpha_2} = 0 \Rightarrow k_{11}\alpha_2 - k_{11}Dy_2 + k_{22}\alpha_2 + Dy_2k_{12} - 2k_{12}\alpha_2 - v_1y_2 + v_2y_2 + y_1y_2 - 1 = 0$$

$$(k_{11} + k_{22} - 2k_{12})\alpha_2 = y_2(k_{11}D - k_{12}D + v_1 - v_2 + y_2 - y_1)$$

$$(k_{11} + k_{22} - 2k_{12})\alpha_2 = y_2(k_{11}D - k_{12}D + v_1 - v_2 + y_2 - y_1)$$

将条件带入: $v_i = f(x_i) - \sum_{j=1}^2 \alpha_j y_j k_{ij} - b$, $\alpha_1 y_1 + \alpha_2 y_2 = D$

$$\Rightarrow y_2 \left[\begin{array}{l} k_{11}(\alpha_1 y_1 + \alpha_2 y_2) - k_{12}(\alpha_1 y_1 + \alpha_2 y_2) \\ + (f_1 - \alpha_1 y_1 k_{11} - \alpha_2 y_2 k_{12} - b) - (f_2 - \alpha_1 y_1 k_{21} - \alpha_2 y_2 k_{22} - b) + y_2 - y_1 \end{array} \right]$$

$$\Rightarrow y_2[(y_2 - y_1) + (f_1 - f_2) + k_{11}\alpha_2 y_2 - 2k_{12}\alpha_2 y_2 + \alpha_2 y_2 k_{22}]$$

$$\Rightarrow y_2[(f_1 - y_1) - (f_1 - y_2) + \alpha_2 y_2(k_{11} - 2k_{12} + k_{22})]$$


$$\text{记: } E_i = f_i - y_i, \quad \eta = k_{11} - 2k_{12} + k_{22}$$

$$\Rightarrow \eta\alpha_2 = y_2[(E_1 - E_2) + \alpha_2 y_2 \eta]$$

$$\Rightarrow \eta\alpha_2 = \alpha_2 \eta + y_2(E_1 - E_2)$$

$$\Rightarrow \alpha_2 = \alpha_2 + \frac{y_2(E_1 - E_2)}{\eta}$$

意义?



类别迭代方法: 比如求解 $f(x) = 0$, 将其在 x_n 进行一阶泰勒展开, $f(x) = f(x_n) + f'(x_n)(x - x_n) = 0$

$$x = x_n - \frac{f(x_n)}{f'(x_n)}, \text{ 将得到的 } x \text{ 看做新的 } x_n \text{ (其实就是 } x_{n+1}) \text{ 进行迭代: } x_{n+1} = x_n - \frac{f(x_n)}{f'(x_n)}$$

$$\alpha_2^{new} = \alpha_2^{old} + \frac{y_2(E_1^{old} - E_2^{old})}{\eta}$$

结合之前的条件: $\alpha_1 y_1 + \alpha_2 y_2 = D$, $\alpha_1 = \frac{(D - \alpha_2 y_2)}{y_1} = y_1(D - \alpha_2 y_2)$

改写为: $\alpha_1^{old} y_1 + \alpha_2^{old} y_2 = D$, $\alpha_1^{new} = y_1(D - \alpha_2^{new} y_2)$

$$\Rightarrow \alpha_1^{new} = y_1(\alpha_1^{old} y_1 + \alpha_2^{old} y_2 - \alpha_2^{new} y_2)$$

$$\Rightarrow \alpha_1^{new} = \alpha_1^{old} + y_1 y_2 (\alpha_2^{old} - \alpha_2^{new})$$

上边的迭代是没有考虑边界条件的，回顾我们要优化的问题以及相应的条件：

$$\max \sum_i \alpha_i - \frac{1}{2} \sum_i \sum_j \alpha_i \alpha_j y_i y_j K(x_i, x_j)$$


$$s.t. \ C \geq \alpha_i \geq 0, \ \mu_i \geq 0, \ \xi_i \geq 0, \ \sum_i \alpha_i y_i = 0$$

$$C \geq \alpha_1 \geq 0, C \geq \alpha_2 \geq 0$$

$$\alpha_1 y_1 + \alpha_2 y_2 = D$$

当 $y_1 \neq y_2$, 即二者异号:

$\Rightarrow \alpha_1 - \alpha_2 = k, k = \pm D$, 并考虑 α_1 和 α_2 的大小关系



$$C \geq \alpha_1 \geq 0, C \geq \alpha_2 \geq 0$$

$$\alpha_1 y_1 + \alpha_2 y_2 = D$$

当 $\alpha_1 > \alpha_2$, $\max \alpha_2 = C - k$, 反之 $\max \alpha_2 = C$,
最大值, 取交集: $H_2 = \min(C, C - \alpha_1 + \alpha_2)$

当 $\alpha_1 > \alpha_2$, $\min \alpha_2 = 0$, 反之 $\min \alpha_2 = -k$,
最小值, 取交集: $L_2 = \max(\alpha_2 - \alpha_1, 0)$

当 $y_1 \neq y_2$, 即二者异号:

$$L_2 \leq \alpha_i \leq H_2$$


其中:

$$H_2 = \min(C, C - \alpha_1 + \alpha_2)$$

$$L_2 = \max(\alpha_2 - \alpha_1, 0)$$

当 $y_1 = y_2$, 即二者同号:

$\Rightarrow \alpha_1 + \alpha_2 = k, k = \pm D$, 亦考虑2种情况。



$$C \geq \alpha_1 \geq 0, C \geq \alpha_2 \geq 0$$

$$\alpha_1 y_1 + \alpha_2 y_2 = D$$

情况1, $\max \alpha_2 = C$, 反之 $\max \alpha_2 = k$,
最大值, 取交集: $H_2 = \min(C, \alpha_1 + \alpha_2)$

情况2, $\min \alpha_2 = k - C$, 反之 $\min \alpha_2 = 0$,
最小值, 取交集: $L_2 = \max(\alpha_1 + \alpha_2 - C, 0)$

当 $y_1 = y_2$, 即二者同号:

$$L_2 \leq \alpha_i \leq H_2$$

其中:

$$H_2 = \min(C, \alpha_1 + \alpha_2)$$


$$L_2 = \max(\alpha_1 + \alpha_2 - C, 0)$$

$$\alpha_2^{new} = \alpha_2^{old} + \frac{y_2(E_1^{old} - E_2^{old})}{\eta}, \quad \alpha_1^{new} = \alpha_1^{old} + y_1 y_2 (\alpha_2^{old} - \alpha_2^{new})$$



$$\alpha_2^{new} = \begin{cases} H_2, & \alpha_2 \geq H_2 \\ \alpha_2^{old} + \frac{y_2(E_1^{old} - E_2^{old})}{\eta}, & \text{else} \\ L_2, & \alpha_2 \leq L_2 \end{cases}$$

$$\alpha_1^{new} = \alpha_1^{old} + y_1 y_2 (\alpha_2^{old} - \alpha_2^{new})$$



为什么 α_1 不需要裁剪?

答: 在 $\alpha_1 y_1 + \alpha_2 y_2 = D$ 的约束下, α_1 和 α_2 被约束到了一条直线上。此时要求的就是, 目标函数在一条平行于对角线的线段上的最优值。这使得两个变量的最优化问题成为实质上的单变量的最优化问题。不妨考虑为 α_2 的最优化问题, 把握住了 α_2 , 那么 α_1 自然就定了。

第 3.5 章 节

α_1 、 α_2 的选取与 b 、 E_i 的推导

KKT for multiple equality & inequality constraints

Given the constrained optimization problem

$$\min_{\mathbf{x} \in \mathbb{R}^2} f(\mathbf{x})$$

subject to

$$h_i(\mathbf{x}) = 0 \text{ for } i = 1, \dots, l \text{ and } g_j(\mathbf{x}) \leq 0 \text{ for } j = 1, \dots, m$$

Define the Lagrangian as

$$\mathcal{L}(\mathbf{x}, \boldsymbol{\mu}, \boldsymbol{\lambda}) = f(\mathbf{x}) + \boldsymbol{\mu}^T \mathbf{h}(\mathbf{x}) + \boldsymbol{\lambda}^T \mathbf{g}(\mathbf{x})$$

Then \mathbf{x}^* a local minimum \iff there exists a unique $\boldsymbol{\lambda}^*$ s.t.

- ① $\nabla_{\mathbf{x}} \mathcal{L}(\mathbf{x}^*, \boldsymbol{\mu}^*, \boldsymbol{\lambda}^*) = \mathbf{0}$
- ② $\lambda_j^* \geq 0$ for $j = 1, \dots, m$
- ③ $\lambda_j^* g_j(\mathbf{x}^*) = 0$ for $j = 1, \dots, m$
- ④ $g_j(\mathbf{x}^*) \leq 0$ for $j = 1, \dots, m$
- ⑤ $\mathbf{h}(\mathbf{x}^*) = \mathbf{0}$
- ⑥ Plus positive definite constraints on $\nabla_{\mathbf{x}\mathbf{x}} \mathcal{L}(\mathbf{x}^*, \boldsymbol{\lambda}^*)$.

$$\textcircled{1} \quad \frac{\partial L}{\partial \mathbf{w}} = 0 \Rightarrow \mathbf{w}^* - \sum_i \alpha_i^* y_i \mathbf{x}_i = 0 \Rightarrow \mathbf{w}^* = \sum_i \alpha_i^* y_i \mathbf{x}_i$$

$$\frac{\partial L}{\partial b} = 0 \Rightarrow -\sum_i \alpha_i^* y_i = 0 \Rightarrow \sum_i \alpha_i^* y_i = 0$$

$$\frac{\partial L}{\partial \xi_i} = 0 \Rightarrow C - \alpha_i^* - \mu_i^* = 0$$

KKT条件在SVM中的表现：指出正确的解应该满足何种形式。

$$\textcircled{2} \quad \alpha_i^* \geq 0, \quad \mu_i^* \geq 0$$

$$\textcircled{3} \quad \alpha_i^* [1 - \xi_i^* - y_i(w^{*T} x_i + b^*)] = 0, \quad -\mu_i^* \xi_i^* = 0$$

$$\textcircled{4} \quad 1 - \xi_i^* - y_i(w^{*T} x_i + b^*) \leq 0, \quad -\xi_i^* \leq 0$$

根据前边的推导，SVM的解应满足KKT条件，且满足原始约束，如 $\alpha_i \geq 0$ ， $\xi_i \geq 0$ 等。从而得到 $C \geq \alpha_i^* \geq 0$ ，由此我们有：

① 当 $\alpha_i^* = 0$ ， $C - \alpha_i^* - \mu_i^* = 0 \Rightarrow \mu_i^* = C \neq 0$ ，又 $y_i(w^{*T} x_i + b) - 1 + \xi_i \geq 0$ ， $\mu_i^* \xi_i^* = 0$ ，得 $\xi_i^* = 0$ ，从而 $y_i(w^{*T} x_i + b) \geq 1$ ，

即 $y_i f(x_i) \geq 1$ 。（对应能够被完美分类的样本）

在实际中是严格大于（小于）

② 当 $0 < \alpha_i^* < C$ ， $C - \alpha_i^* - \mu_i^* = 0 \Rightarrow \mu_i^* = C - \alpha_i^* \neq 0$ ，又 $\alpha_i^* [1 - \xi_i^* - y_i(w^{*T} x_i + b^*)] = 0$ ，得 $1 - \xi_i^* - y_i(w^{*T} x_i + b^*) = 0$ ，又 $\mu_i^* \xi_i^* = 0$ ，所以 $\xi_i^* = 0$ ，从而 $y_i(w^{*T} x_i + b) = 1$ ，即 $y_i f(x_i) = 1$ 。（对应卡在边界的样本，即支持向量）

③ 当 $\alpha_i^* = C$ ， $C - \alpha_i^* - \mu_i^* = 0 \Rightarrow \mu_i^* = 0$ ，又 $1 - \xi_i^* - y_i(w^{*T} x_i + b^*) = 0 \Rightarrow y_i(w^{*T} x_i + b^*) = 1 - \xi_i^*$ ，又 $\mu_i^* \xi_i^* = 0$ ，得 $\xi_i^* \geq 0$ ，从而 $y_i(w^{*T} x_i + b) \leq 1$ ，即 $y_i f(x_i) \leq 1$ 。（对应超平面和边界之间的样本）

等价KKT条件: ① $\alpha_i^* = 0 \Leftrightarrow y_i f(x_i) \geq 1$ 。② $0 < \alpha_i^* < C \Leftrightarrow y_i f(x_i) = 1$ 。③ $\alpha_i^* = C \Leftrightarrow y_i f(x_i) \leq 1$ 。

$$\alpha_i \text{ 的更新公式: } \alpha_1^{new} = \alpha_1^{old} + y_1 y_2 (\alpha_2^{old} - \alpha_2^{new}), \alpha_2^{new} = \begin{cases} H_2, & \alpha_2 \geq H_2 \\ \alpha_2^{old} + \frac{y_2(E_1^{old} - E_2^{old})}{\eta}, & \text{else} \\ L_2, & \alpha_2 \leq L_2 \end{cases}$$

● α_1 、 α_2 的选取

- **外循环先选 α_1** ：目标是尽量选取违反KKT条件的变量，并且优先判断支撑边界上的样本对应的 α 。具体操作为，先检验 $0 < \alpha_i < C$ ，对应的 $y_i f(x_i) = 1$ 是否成立？选择不成立、结果差的最离谱的 α_i 作为此次的 α_1 。如果都满足，则再遍历其余样本。
- **内循环选择 α_2** ：思路是，在选定 α_1 的基础上，选一个 α_2 能够有足够大的变动：具体为，因为 α_2^{new} 的变动量是与 $|E_1 - E_2|$ 成正比的，而 α_1 选定之后， E_1 就定了。所以，如果 E_1 是正的，那么选择最小的 E_i 的对应的 α_i 作为 α_2 ，反之选择最大的 E_i 的对应的 α_i 作为 α_2 。
 - 如果上述的选择方式不能使 α_2 能够有足够大的变动（变动量小于某个阈值），那么启发式的遍历支持向量对应的 α_i 作为 α_2 ，判断是否能够满足条件。再不行，那就遍历其余样本，最后，实在不行，那就换个 α_1 。

- 截距 b 的计算:

- 若 $0 < \alpha_1^{new} < C$, $y_i(w^T x_i + b) = 1 \Rightarrow w^T x_i + b = y_i \Rightarrow y_i = b - w^T x_i$

$$b_1^{new} = y_1 - \sum_{i=3} \alpha_i y_i k_{i1} - \alpha_1^{new} y_1 k_{11} - \alpha_2^{new} y_2 k_{21}$$

$$E_1^{old} = \sum_{i=3} \alpha_i y_i k_{i1} + \alpha_1^{old} y_1 k_{11} + \alpha_2^{old} y_2 k_{21} + b^{old} - y_1$$

$$\Rightarrow b_1^{new} = \left(-E_1^{old} + \sum_{i=3} \alpha_i y_i k_{i1} + \alpha_1^{old} y_1 k_{11} + \alpha_2^{old} y_2 k_{21} + b^{old} \right) - \sum_{i=3} \alpha_i y_i k_{i1} - \alpha_1^{new} y_1 k_{11} - \alpha_2^{new} y_2 k_{21}$$

$$\Rightarrow b_1^{new} = -E_1^{old} + (\alpha_1^{old} - \alpha_1^{new}) y_1 k_{11} + (\alpha_2^{old} - \alpha_2^{new}) y_2 k_{21} + b^{old}$$

- 若 $0 < \alpha_2^{new} < C$, 同理

$$\Rightarrow b_2^{new} = -E_2^{old} + (\alpha_1^{old} - \alpha_1^{new}) y_1 k_{12} + (\alpha_2^{old} - \alpha_2^{new}) y_2 k_{22} + b^{old}$$

哪个 α 满足条件, 就 $b^{new} = b_i^{new}$, 否则就取二者均值作为新的 b 。

- E_i 的计算:

$$E_i^{new} = \sum \alpha_j^{new} y_j k_{ji} + b^{new} - y_i$$

● 算法流程

● 输入：训练集 n 个样本 (x_i, y_i) , $x_i \in R^N, y_i \in \{+1, -1\}$, 精度 ϵ , 输出： α

① 初始化迭代次数 $k = 0$, 设置 $\alpha_i^k = 0$

② 选择 α_1^k 、 α_2^k , 并计算

$$E_i^k = \alpha_1^k y_1 k_{1i} + \alpha_2^k y_2 k_{2i} + \sum_{j=3} \alpha_j y_j k_{ji} - y_i, \quad \eta = k_{11} - 2k_{12} + k_{22}$$

③ 更新计算 α_1^{k+1} 、 α_2^{k+1}

$$\alpha_2^{k+1} = \alpha_2^k + \frac{y_2(E_1^k - E_2^k)}{\eta}, \text{clip}, \quad \alpha_1^{k+1} = \alpha_1^k + y_1 y_2 (\alpha_2^k - \alpha_2^{k+1})$$

④ 更新计算 b^{k+1} 、 E_i^{k+1}

$$b_1^{new} = -E_1^{old} + (\alpha_1^{old} - \alpha_1^{new}) y_1 k_{11} + (\alpha_2^{old} - \alpha_2^{new}) y_2 k_{21} + b^{old}$$

$$b_2^{new} = -E_2^{old} + (\alpha_1^{old} - \alpha_1^{new}) y_1 k_{12} + (\alpha_2^{old} - \alpha_2^{new}) y_2 k_{22} + b^{old}$$

$$E_i^{new} = \sum \alpha_j^{new} y_j k_{ji} + b^{new} - y_i$$

⑤ 是否在 ϵ 范围内满足KKT条件

$$\sum_i \alpha_i y_i = 0, y_i f(x_i): \begin{cases} \geq 1, & \{x_i | \alpha_i = 0\} \\ = 1, & \{x_i | 0 < \alpha_i < C\} \\ \leq 1, & \{x_i | \alpha_i = C\} \end{cases}$$

⑥ $k = k + 1$

di si zhang jie

第	四	章	节
---	---	---	---

深度学习版本的SVM

(☆☆☆)

深度学习版本的SVM，指的是使用DL中构造损失函数，利用误差反向传播，梯度下降的思路进行求解。

本节相关内容、图像来自[李宏毅老师16年ML课程课件](#)。

Binary Classification

x^1	x^2	x^3	...
\hat{y}^1	\hat{y}^2	\hat{y}^3	...

$$\hat{y}^n = +1, -1$$

- Step 1: Function set (Model)

$$g(x) = \begin{cases} f(x) > 0 & \text{Output} = +1 \\ f(x) < 0 & \text{Output} = -1 \end{cases}$$

- Step 2: Loss function:

$$L(f) = \sum_n \frac{\delta(g(x^n) \neq \hat{y}^n)}{l(f(x^n), \hat{y}^n)}$$

The number of times g get incorrect results on training data.

- Step 3: Training by gradient descent is difficult

Gradient descent is possible if $g(*)$ and $\delta(*)$ is differentiable

Step 2: Loss function


$$g(x) = \begin{cases} f(x) > 0 & \text{Output} = +1 \\ f(x) < 0 & \text{Output} = -1 \end{cases}$$

Ideal loss:

$$L(f) = \sum_n \delta(g(x^n) \neq \hat{y}^n)$$


Approximation:

$$L(f) = \sum_n l(f(x^n), \hat{y}^n)$$



Step 2: Loss function

Square Loss: If $\hat{y}^n = 1$, $f(x)$ close to 1
If $\hat{y}^n = -1$, $f(x)$ close to -1




Square Loss

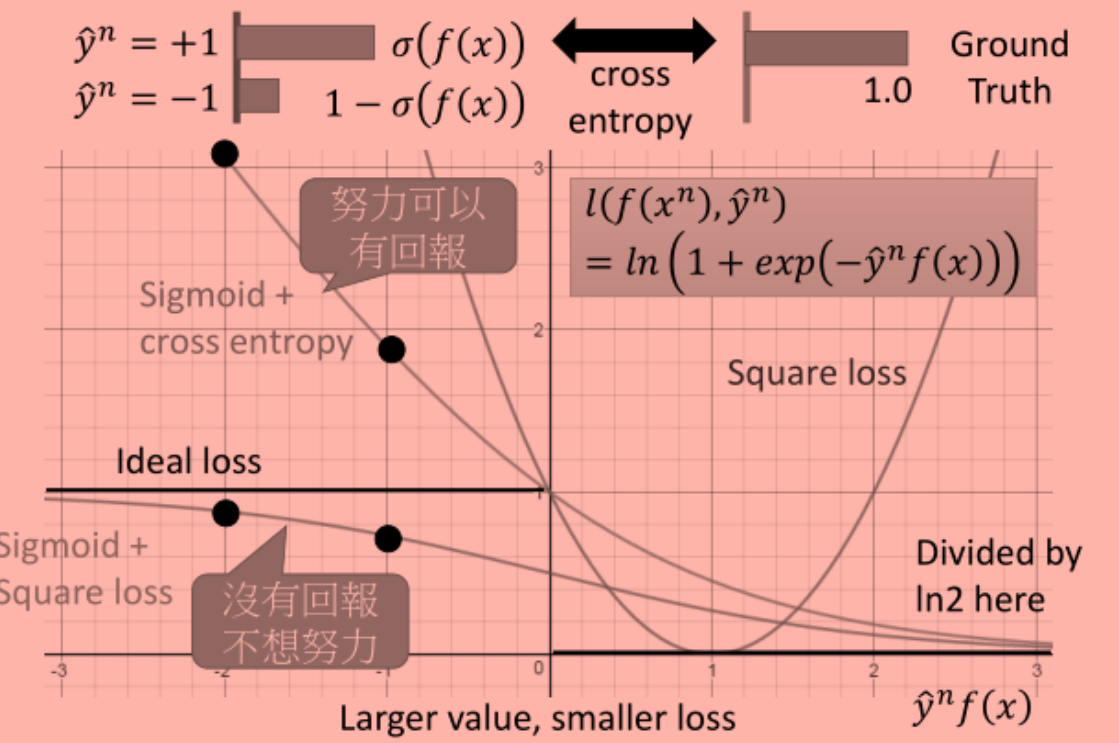
Sigmoid + Square Loss

Step 2: Loss function

Sigmoid + Square Loss: If $\hat{y}^n = 1$, $\sigma(f(x))$ close to 1
If $\hat{y}^n = -1$, $\sigma(f(x))$ close to 0



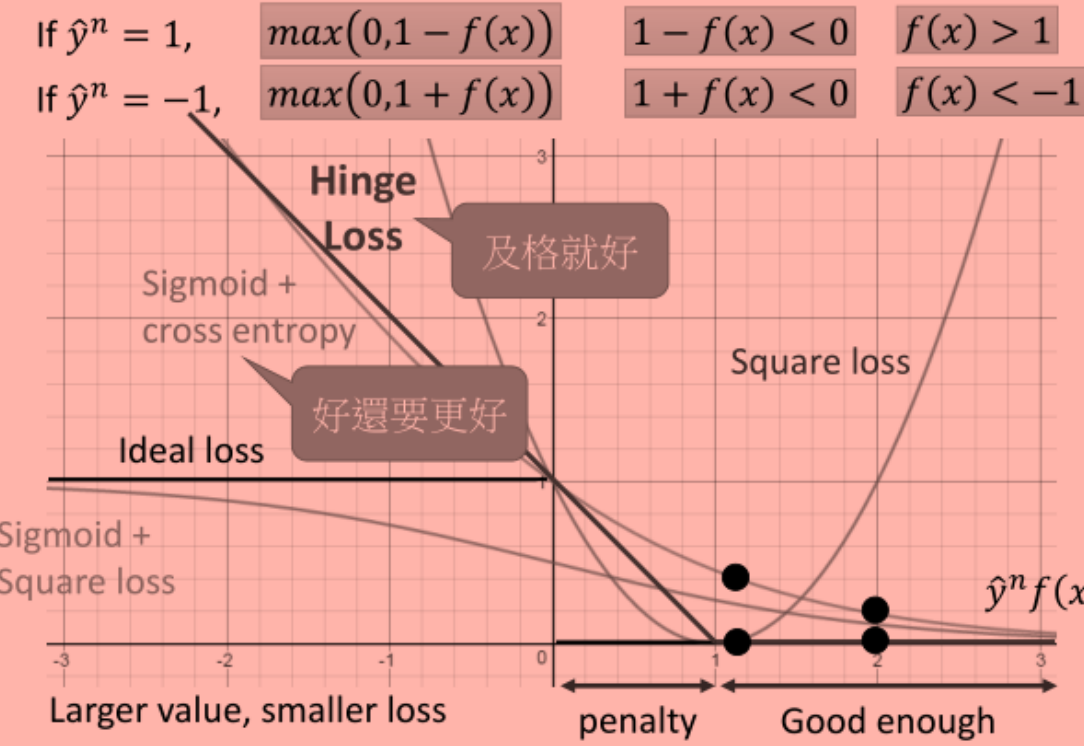
Step 2: Loss function Sigmoid + cross entropy (logistic regression)



Sigmoid + Cross Entropy

Hinge Loss

Step 2: Loss function $l(f(x^n), \hat{y}^n) = \max(0, 1 - \hat{y}^n f(x))$



接下来证明, 对于 n 个训练样本, 如果对如下函数进行最小化, 那么你得到的就是一个SVM。

$$\text{Minimize } L(f) = \sum l(f(x^n), \hat{y}^n) + \lambda \|w\|_2, \quad l(f(x^n), \hat{y}^n) = \max(0, 1 - \hat{y}^n f(x^n))$$

Proof:

$$\text{Minimize } L(f) = \sum \epsilon^n + \lambda \|w\|_2, \quad \epsilon^n = \max(0, 1 - \hat{y}^n f(x^n))$$

$$\epsilon^n = \max(0, 1 - \hat{y}^n f(x^n))$$



$$\epsilon^n \geq 0, \quad \epsilon^n \geq 1 - \hat{y}^n f(x^n)$$

But!!!

$$\epsilon^n = \max(0, 1 - \hat{y}^n f(x^n))$$



Minimize



$$\epsilon^n \geq 0, \quad \epsilon^n \geq 1 - \hat{y}^n f(x^n)$$



Minimize

$$\text{Minimize } L(f) = \sum \epsilon^n + \lambda \|w\|_2, \quad \epsilon^n \geq 0, \quad \hat{y}^n f(x^n) \geq 1 - \epsilon^n$$

PPT13页, 软间隔SVM目标: $\min \frac{1}{2} w^T w + C \sum_i \xi_i, \quad \text{s.t. } y_i (w^T x_i + b) \geq 1 - \xi_i, \quad \xi_i \geq 0$

Linear SVM – gradient descent

Ignore regularization for simplicity

$$L(f) = \sum_n l(f(x^n), \hat{y}^n) \quad l(f(x^n), \hat{y}^n) = \max(0, 1 - \hat{y}^n f(x^n))$$

$$\frac{\partial l(f(x^n), \hat{y}^n)}{\partial w_i} = \frac{\partial l(f(x^n), \hat{y}^n)}{\partial f(x^n)} \boxed{\frac{\partial f(x^n)}{\partial w_i}} x_i^n \quad \boxed{f(x^n) = w^T \cdot x^n}$$

$$\frac{\partial \max(0, 1 - \hat{y}^n f(x^n))}{\partial f(x^n)} = \begin{cases} -\hat{y}^n & \text{if } \hat{y}^n f(x^n) < 1 \\ 0 & \text{otherwise} \end{cases}$$

$$\frac{\partial L(f)}{\partial w_i} = \sum_n \frac{-\delta(\hat{y}^n f(x^n) < 1) \hat{y}^n x_i}{c^n(w)} \quad w_i \leftarrow w_i - \eta \sum_n c^n(w) x_i^n$$

亦可以说明SVM的权重 w ，是训练集样本的线性组合

Dual Representation

$$w^* = \sum_n \alpha_n^* x^n \quad \text{Linear combination of data points}$$

α_n^* may be sparse $\Rightarrow x^n$ with non-zero α_n^* are support vectors

$$\left. \begin{aligned} w_1 &\leftarrow w_1 - \eta \sum_n c^n(w) x_1^n \\ &\vdots \\ w_i &\leftarrow w_i - \eta \sum_n c^n(w) x_i^n \\ &\vdots \\ w_k &\leftarrow w_k - \eta \sum_n c^n(w) x_k^n \end{aligned} \right\}$$

If w initialized as $\mathbf{0}$

$$w \leftarrow w - \eta \sum_n c^n(w) x^n$$

$$c^n(w) = \frac{\partial l(f(x^n), \hat{y}^n)}{\partial f(x^n)} \quad \text{Hinge loss: usually zero}$$

c.f. for logistic regression, it is always non-zero

第 4.5 章 节

SVM与逻辑回归、回归任务、 NN的关系

$$\text{Minimize } L(f) = \sum l(f(x^n), \hat{y}^n) + \lambda \|w\|_2$$


使用不同的损失函数对上式进行优化，得到的就是不同的模型。

- ① 当 $l(f(x^n), \hat{y}^n) = \max(0, 1 - \hat{y}^n f(x^n))$ 时，得到就是一个SVM。
- ② 当 $l(f(x^n), \hat{y}^n) = \ln(1 + \exp(-\hat{y}^n f(x^n)))$ 时，得到就是一个 Logistics Regression 。
- ③ 当 $l(f(x^n), \hat{y}^n) = (f(x^n) - \hat{y}^n)^2$ 时，得到的就是一个带 L2 Regularization 的回归模型，也叫 岭回归。
- ④ 当 $l(f(x^n), \hat{y}^n) = (f(x^n) - \hat{y}^n)^2$ ，且 $+\lambda \|w\|_1$ 时，得到是 L1 Regularization 的回归模型，也叫 LASSO回归。


因此，从这个角度，SVM、逻辑回归、带正则项的回归，他们是一样的。区别仅在于选择什么优化函数。

具体L1，L2正则化的原理、理解，读者自行学习。推荐一个B站UP [王木头学科学](#) 的视频：



Deep Learning**SVM**

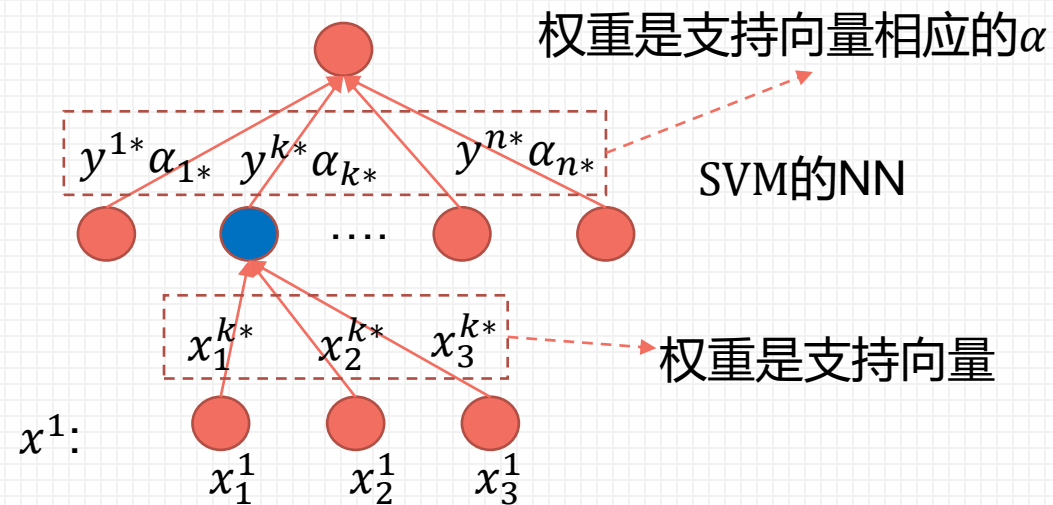
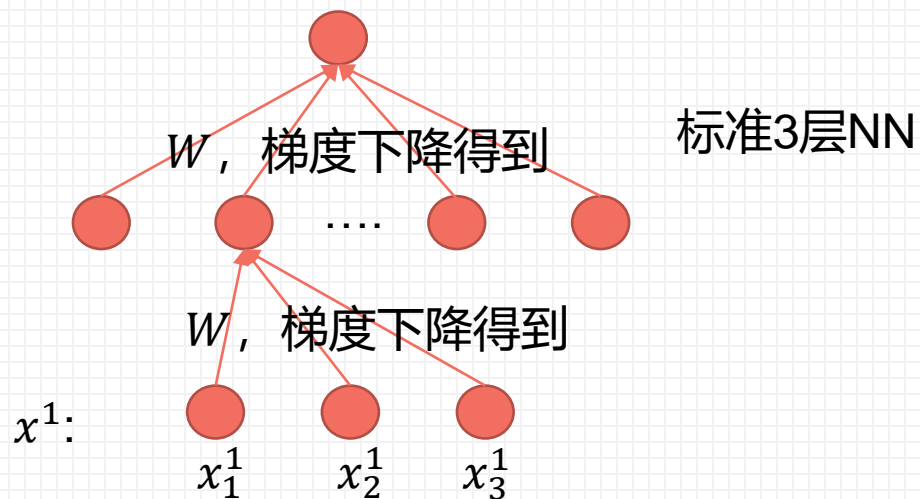
Based on
kernel
function



Multiple Kernel
learning [Alpaydin,
Chapter 13.8]

训练的时候:

NN的隐藏层一定程度上要做的事情
和 SVM 中 $\phi(\cdot)$ 要做的事情类似。



$$f(x^i) = w^T x^i, w = \sum \alpha_{n*} y^{n*} x^{n*}, \text{忽略偏置、} \varphi(\cdot)$$

$$f^i = \sum \alpha_{n*} y^{n*} (x^{n*} \cdot x^i), x^{n*} \text{为支持向量}$$

预测的时候:

SVM也是可以写成单个隐含层的神经网络, 其中权重是支持向量和其相应的 α

di wu zhang jie

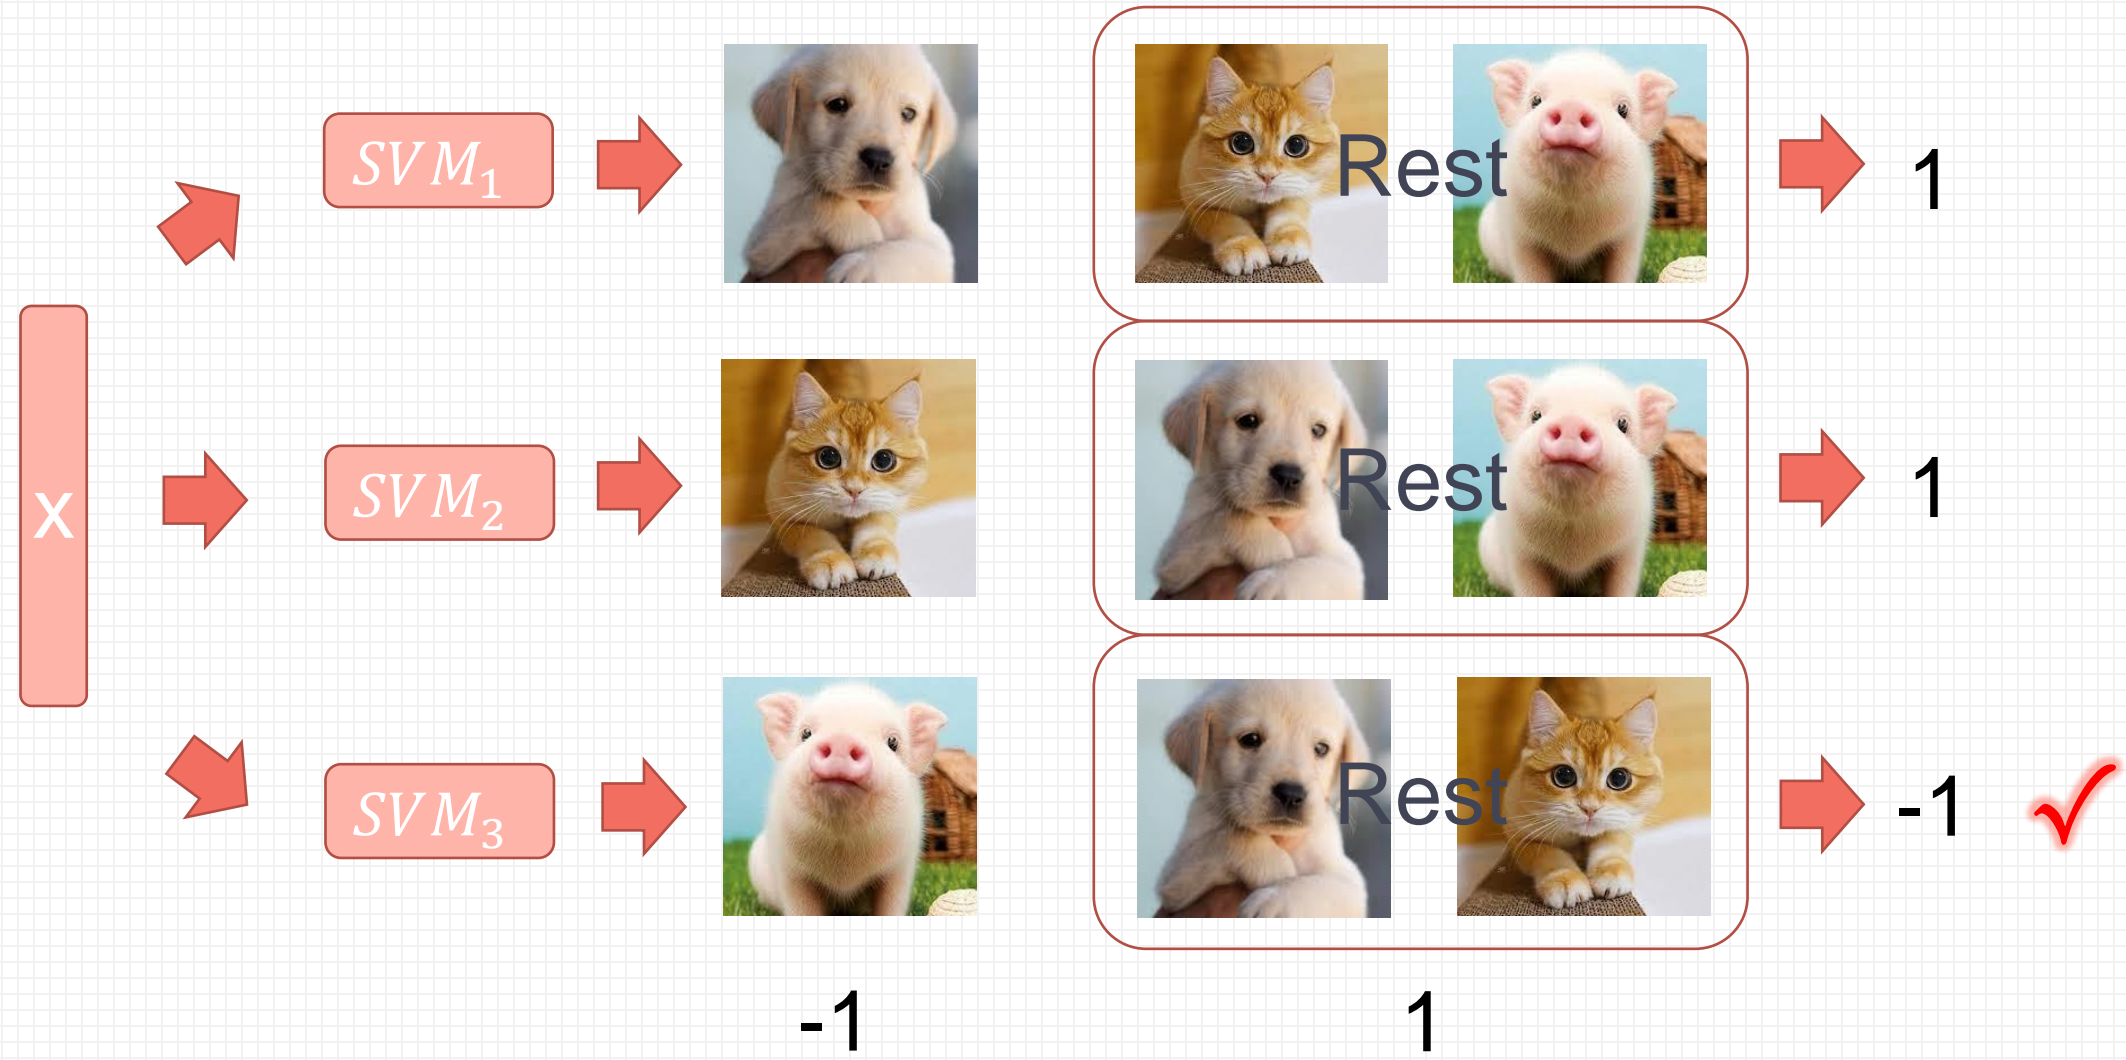
第	五	章	节
---	---	---	---

SVM的程序调用

(☆☆☆)

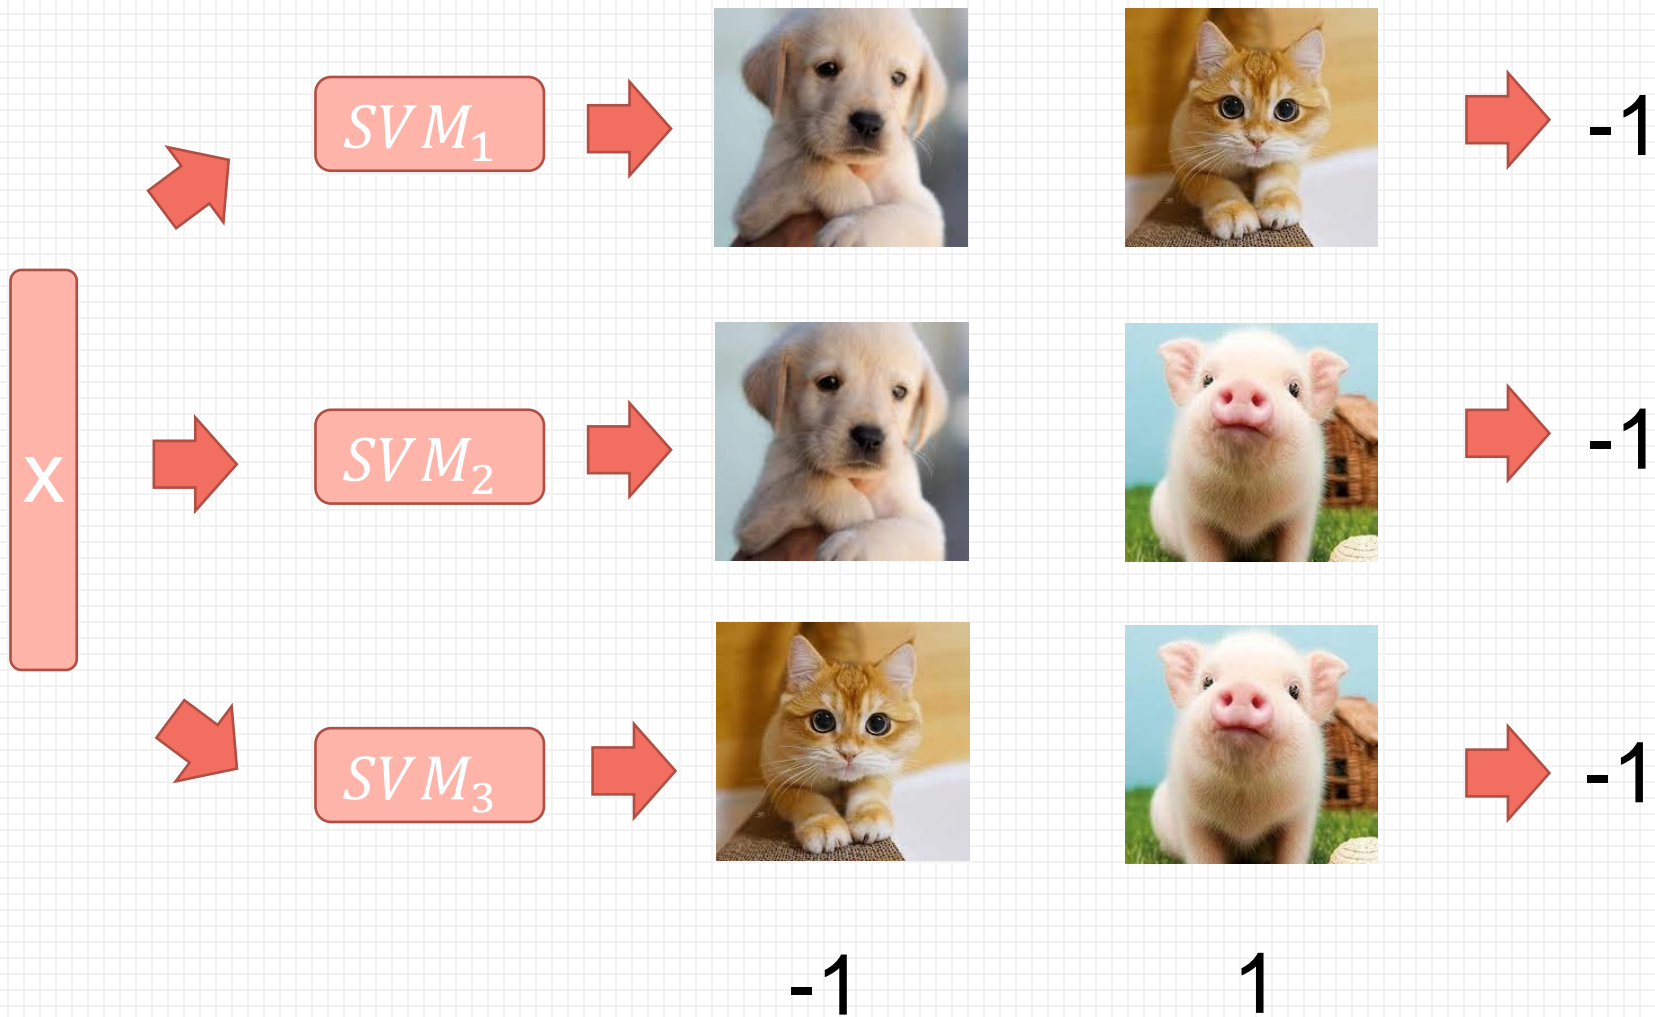
SVM怎么做多分类?

① one-vs-rest (OVR) : 思路简单, 高效。需要比k次, 即训练k个模型, k为类别数目。



SVM怎么做多分类?

② one-vs-one (OVO) : 准确, 慢。需要比 $k(k-1)/2$ 次, 即训练个 $k(k-1)/2$ 模型, k 为类别数目。



- 顺序要对应:
比如狗、猫、猪
最后输出才能对上:
(-1, -1, -1) 对应
(狗, 猫)、(狗、猪)、
(猫, 猪)。
- 输出的-1含义不一样,
需要额外的信息标识。
- 最后采用投票法输出
最终结果


Standard SVM:

<https://scikit-learn.org/stable/modules/generated/sklearn.svm.SVC.html>

For Large Dataset :

<https://scikit-learn.org/stable/modules/generated/sklearn.svm.LinearSVC.html#sklearn.svm.LinearSVC>

https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.SGDClassifier.html#sklearn.linear_model.SGDClassifier



本次课程部分图片内容来自[李宏毅老师ML课程](#)，感谢老师的精彩课程讲解及相关开源内容。

所有课程PPT以及code下载链接（或者评论区、视频简介均可下载）：

<https://github.com/CHENHUI-X/My-lecture-slides-and-code>，如果对你有帮助，可以  支持我。

UP知识水平有限，且PPT内容公式较多，纯手工敲写，相关内容如有错误及不足，请务必指出，感谢。

THANKS

谢谢观看

